

Բովանդակություն

Ներածություն

## **Գլուխ 1 Վիճակագրության նշանակությունը տվյալների վերլուծությունում**

1.1 Վիճակագրությունը որպես գիտական դիսցիպլինա

1.2 Տվյալների վերլուծության հիմնական գործառույթը

## **Գլուխ 2 Վիճակագրական ոչ պարամետրական մեթոդներ**

2.1 Վիճակագրական մեթոդների դասակարգում. պարամետրական և ոչ պարամետրական մեթոդներ

2.1.1 Տվյալների թվային բնութագրիչներ: Վիճակագրական վարկած, տեստի հզորություն:

2.2 Երեք և ավելի խմբերի համեմատման Կրուսկալ-Ուոլլիսի / Kruskal–Wallis/ հայտանիշ

2.2.1 Ձույզ – առ-զույգ խմբային համեմատություն

## **Գլուխ 3 Ծրագրային մասը**

3.1 Տվյալների միջոցով ուսումնասիրված մեթոդների գործնական կիրառություն  
Python լեզվով-----

3.2 .....

.....

# Գլուխ 1 Վիճակագրության նշանակությունը տվյալների վերլուծությունում

## 1.1. Վիճակագրությունը որպես գիտական դիսցիպլինա

Վիճակագրությունը մաթեմատիկական գիտություն է, որը զբաղվում է տվյալների հավաքմամբ, դասակարգմամբ, վերլուծությամբ: Վերջնարդյունքում ընդունվում են որոշումներ, կատարվում եզրակացություններ՝ տալով դրանց հավանականային գնահատական: Այն օգնում է պատահականության հիմքի վրա, տվյալներից որոշումներ կայացնել ուսունասիրվող երևույթների վերաբերյալ:

Երբ ուսումնասիրվում են, օրինակ, բնակչության եկամուտները, ուսանողների գնահատականները, կայքի այցելությունները և այլն, դրանց վերաբերյալ կուտակված տվյալների հիման վրա, բնականաբար անհնար է ամեն մի տվյալ առանձին ուսումնասիրել: Վիճակագրությունը տվյալների վերլուծության փուլերում թույլ է տալիս՝

---Ամփոփ նկարագրել այդ տվյալները (օր.՝ միջին, տատանում, տոկոսներ);

--- Վիզուալիզացնել;

---Գտնել օրինաչափություններ, փոխկապվածություններ;

---- Եվ այդ մասնավոր տվյալների հիման վրա անել եզրակացություններ, կայացնել որոշումները ընդհանուր հանուրի վերաբերյալ:

Վիճակագրությունը բաժանվում է երկու խմբի՝ մաթեմատիկական վիճակագրություն և կիրառական վիճակագրություն:

Կիրառական վիճակագրությունը այնպիսի եղանակների, ընթացակարգերի ու հնարքների համակարգ է, որոնք հնարավորություն են տալիս փորձնական տվյալները

հիմնավորված ձևով հավաքել, կազմավորել, ի մի բերել, ներկայացնել և վերլուծել՝ դրանց հիման վրա եզրահանգումներ անելու և որոշումներ ընդունելու նպատակով:

Մաթեմատիկական վիճակագրության խնդիրն է հիմնավորել, կատարելագործել և զարգացնել այդ եղանակներն ու ընթացակարգերը, ընդլայնել դրանց ներգործության ոլորտը: Մաթեմատիկական վիճակագրության եղանակների մեծ մասը հիմնված է հավանականության տեսության գաղափարների և արդյունքների վրա: Դա թույլ է տալիս, մասնավորապես, գնահատել վիճակագրական նյութի հիման վրա արված եզրակացությունների հուսալիությունը և ճշգրտությունը:

## 1.2 Տվյալների վերլուծության հիմնական գործառույթը

Տվյալների վերլուծությունը այն գործընթացն է, որի ընթացքում հավաքված տվյալները ուսումնասիրվում, մշակվում և մեկնաբանվում են՝ օգտակար տեղեկատվություն ստանալու, եզրակացություններ անելու կամ որոշումներ ընդունելու համար:

Տվյալների վերլուծությունը կատարվում է հետևյալ փուլերով՝

1.Տվյալների հավաքում. տվյալները կարող են գալ հարցումների, դիտարկումների, ֆայլերի, բազաների, սոցցանցերի կամ սենսորների միջոցով:

2.Տվյալների մաքրում. հեռացվում կամ ուղղվում են սխալ, կրկնվող կամ բացակայող արժեքները:

3.Տվյալների ուսումնասիրում. տեսողական (գրաֆիկներ, աղյուսակներ) և վիճակագրական (միջին, տատանում, կոռելացիա) ուսումնասիրություն՝ հասկանալու համար տվյալների կառուցվածքն ու օրինաչափությունները:

4.Տվյալների մոդելավորում. օգտագործվում են մաթեմատիկական կամ մեքենայական ուսուցման մոդելներ՝ կանխատեսումներ կամ դասակարգումներ անելու համար:

5.Եզրակացություններ և ներկայացում. արդյունքները ներկայացվում են գրաֆիկների, հաշվետվությունների կամ ղեշբորդների տեսքով՝ հեշտ ընկալման համար:

Ստորև ներկայացված է, թե յուրաքանչյուր փուլ ինչ է ներկայացնում իրենից՝

1.Տվյալների վերլուծության ամենակարևոր փուլերից մեկն տվյալների հավաքումն է, որովհետև եթե տվյալները սխալ կամ անորակ են, վերլուծությունն էլ չի կարող ճշգրիտ լինել:

2.Եթե հավաքված տվյալները «կեղտոտ» են՝ ունեն սխալներ, բաց արժեքներ կամ անհամապատասխան ձևաչափեր, ապա վերլուծության բոլոր արդյունքները կարող են լինել սխալ կամ մոլորեցնող:

3.Տվյալների ուսումնասիրումը տվյալների վերլուծության փուլերից է, որի նպատակն է՝ լավ ճանաչել տվյալները, հասկանալ դրանց կառուցվածքը, օրինաչափությունները, կապերը և առանձնահատկությունները մինչև բարդ մոդելների կամ կանխատեսումների կիրառումը: Տվյալների ուսումնասիրության ընթացքում տրվում է տվյալների հիմնական նկարագրություն, կատարվում է վիճակագրական ամփոփում (հաշվարկվում են հիմնական վիճակագրական բնութագրիչները՝ միջին, մեդիան, մաքսիմում և մինիմում արժեքներ, տատանում և այլն): Այնուհետև կատարվում է տվյալների բաշխման վիզուալ ուսումնասիրություն: Այս փուլին են պատկանում անհրաժեշտության դեպքում անոմալիաների և արտառոց արժեքների հայտանքերում:

4.Տվյալների մոդելավորումը այն փուլն է, երբ արդեն մաքրված և ուսումնասիրված տվյալների հիման վրա կառուցվում է մաթեմատիկական կամ վիճակագրական մոդել, որը կարող է բացատրել, կանխատեսել կամ դասակարգել երևույթները: Եթե մոդելավորման ընթացքում կիրառվում են մեքենայական ուսուցման ալգորիթմները, ապա նախ տվյալները բաժանում ենք երկու մասի՝ ուսուցման տվյալներ և թեստավորման տվյալներ: Այնուհետև ընտրում ենք մոդելը՝ կախված խնդրի բնույթից: Հիմնականում այս մոտեցումը դիտվում է մեծածավալ տվյալների հետ աշխատելու ժամանակ: Վիճակագրական վերլուծությունը, ի տարվերություն մեքենայական ուսուցման, չի պահանջում կատարել տվյալների տրոհում, այլ առկա տվյալների

հիման վրա կատարվում է վերլուծություն, վերլուծության արդյունքները գնահատվում են հավանականությամբ, կառուցվում են վստահության միջակայքերը և այլն:

5.Վերջին փուլում տվյալները և մոդելի արդյունքները հասկանալի ձևի ենք վերածում և կատարում ենք եզրակացություններ, որոնք պետք է տանեն հստակ գործողությունների և խնդիրների լուծման:

## Գլուխ 2 Վիճակագրական ոչ պարամետրական մեթոդներ

### 2.1 Վիճակագրական մեթոդների դասակարգում. պարամետրական և ոչ պարամետրական մեթոդներ

Վիճակագրական վերլուծության ժամանակ կախված տվյալներից, վերլուծության պահանջներից, կիրառվում են համապատասխան վիճակագրական մեթոդներ:

Վիճակագրական մեթոդները իրենց հերթին բաժանվում են երկու խմբի՝

---Պարամետրական մեթոդներ;

---Ոչ պարամետրական մեթոդներ:

Պարամետրական մեթոդները այն մեթոդներն են, որոնք ենթադրում են, որ տվյալները գալիս են որևէ հայտնի տեսքով բաշխումից, մասնավորապես, ամենից հաճախ դրվող պայմանը վերաբերում է նորմալ բաշխվածությանը: Եթե հստակ չկա ինֆորմացիա բաշխվածության վերաբերյալ, պարամետրական մեթոդը կիրառելու համար նախապես՝ վարկածների ստուգման միջոցով, հիմնավորվում է նորմալ բաշխման և նրա պարամետրերի՝ միջին, դիսպերսիա, վերաբերյալ ենթադրության հավաստիությունը, որից հետո պարամետրական մեթոդի կիրառման արդյունքում արվող որոշումները կարող ենք համարել հավաստի: Հիմնականում պարամետրական մեթոդները

կիրառվում են հենց տվյալների վրա: Հայտանիշը, որը մեզ թույլ է տալիս տվյալներից կորզել անհրաժեշտ ինֆորմացիան, մաթեմատիկական դրվածքով հանդիսանում է տվյալներից ֆունկցիա, որի բանաձևային նկարագրությունը տրվում է տվյալներից ստացվող միջինի, ուղղված դիսպերսիան և այլն միջոցով:

Ոչ պարամետրական մեթոդները չեն պահանջում որևէ բաշխման առկայություն Դրանք չեն օգտագործում խիստ բաշխումներ, ի տարբերություն պարամետրական մեթոդների, ոչ պարամետրական մեթոդները հիմնվում են տվյալների կարգերի՝ ռանգերի վրա, իրականացվում է կարգային համեմատություններ՝ օգտվելով կիսողներից, քանորդիչներից և այլն:

Ոչ պարամետրական առավել հաճախ կիրառվող մեթոդներից են՝

1. Mann–Whitney U test , Wilcoxon Signed-Rank test: Կախյալ և անկախ նմուշների համեմատության պարամետրական t-test-ի ոչ պարամետրական անալոգը համապատասխանաբար Վիլկոնսոնի և Մանն Վիտի տեստերն են, որոնք իրականացնում են զույգ դիտարկումներին համապատասխանող տարբերությունների մեդիանային հավասարության վարկածի ստուգումը:
2. Kruskal–Wallis test: Միագործոն պարամետրական վերլուծության՝ one-way-ANOVA, ոչ պարամետրական անալոգը Կրուսկալ–Ուոլլիսի թեստն է: Այն իրականացնում է գործոնի մակարդակներին համապատասխանող տրոհված խմբերի կիսողների հավասարության վարկածի ստուգումը: Այս թեստը հիմնավորված է դիտարկումների ռանգավորման վրա:
3. Spearman-ի կոռելացիա: Պարամետրական գծային կոռելյացիայի ոչ պարամետրական անալոգը ոչ գծային կապերի չափման Սպերմանի կարգային կոռելյացիան է: Այն իրականացնում է երկու քանակական փոփոխականների միջև մոնոտոն կախվածության առկայության մասին վարկածի ստուգումը՝ դարձյալ հիմնվելով տվյալների կարգային ներկայացման վրա:

4. Պիրսոնի  $\chi^2$  տեսուր: Որակական հատկանիշների կապերի բացահայտման, անկախության վերաբերյալ վարկածի և բաշխման պատկանելիության վարկածի ստուգման համար կիրառվում են Պիրսոնի կողմից առաջարկված համապատասխան տեսուերը:

Ոչ պարամետրական մեթոդները ունեն ինչպես առավելություններ, այնպես էլ թերություններ.

Առավելությունները՝

--Կիրառելի են անկախ տվյալների բաշխվածության վերաբերյալ տեղեկության

--Հնարավորություն են տալիս վերլուծություն կատարել փոքր ծավալի տվյալների՝ նմուշների հիման վրա:

Հիմնական թերությունը կայանում է նրանում, որ դրանք զիջում են իրենց պարամետրական անալոզին տեստի հզորության առումով:

### 2.1.1 Տվյալների թվային բնութագրիչներ: Վիճակագրական վարկած, տեստի հզորություն

Վիճակագրական վերլուծության առաջին փուլերից է տվյալները ամփոփ բնութագրիչների միջոցով նկարագրելը: Այս ենթաբաժնում կսահմանենք այդ կարևոր հասկացությունները:

Որոշակի ուսումնասիրման ենթակա բոլոր առարկաների բազմությունը կանվանենք **համախումբ** (անգլերեն՝ population): Նրա տարրը կոչվում է **անհատ**: Անհատների դիտարկվող հատկությունները կոչվում են **հատկանիշներ**: Դրանք կարող են լինել որակական կամ քանակական:

Համախմբի այն մասը, որը վերցվում է քննության համար, կոչվում է **նմուշ/sample/**, իսկ նմուշի ստացման գործընթացը՝ **նմուշահանում/sampling/**:

Համախմբից վերցված պատահական նմուշահանմանը համապատասխանող անհատների հատկանիշների ( $X_1, X_2, \dots, X_n$ ) պատահական վեկտորը կոչվում է նմուշ մինչև փորձարկումը կամ դիտարկումը, իսկ փորձարկումից հետո ստացված ( $x_1, x_2, \dots, x_n$ ) հաջորդականությունը կոչվում է նմուշ փորձարկումից հետո (հավանականությունների տեսությունում  $X_1, X_2, \dots, X_n$ -ը անկախ միատեսակ բաշխված պատահական մեծությունների հաջորդականություն է):

$X$  հատկանիշի չափումներից ստացված տվյալները կոչվում են չմշակված: Չնվազման կարգով վերադասավորված չմշակված տվյալների հաջորդականությունը կոչվում է փոփոխման (վարիացիոն) շարք: Փոփոխման շարքի անդամները նշանակվում են  $x_{(k)}$ -ով և կոչվում են կարգային վիճականիներ՝

$$x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}:$$

Հավաքագրելով քանակական տվյալները, բացի աղյուսակներից և գծապատկերներից, պահանջվում է ստանալ նաև այդ տվյալների բաշխումները նկարագրող այլ թվային բնութագրիչներ: Այդ բնութագրիչների թվին են պատկանում կենտրոնական դիրքը և ցրվածությունը նկարագրող բնութագրիչները:

Շատ դեպքերում տվյալները ցուցաբերում են ակնհայտ միտում խմբավորվելու որոշակի կենտրոնական արժեքների շուրջ: Կենտրոնական դիրքի բնութագրիչները ներկայացնում են այն թվային ցուցանիշները, որոնք բնութագրում են տվյալների բաշխման կենտրոնական միտումը՝ սահմանելով այն արժեքները, որոնց շուրջ դիտարկվող մեծության իրականացումները ընդհանուր առմամբ տեղակայված են: Դրանք են՝ *միջինը* (միջին թվաբանականը), *մեդիանը* (կիսողը, որը կոչվում է նաև՝ միջնակետ կամ միջնարժեք) և *մոդը*՝ ամենահաճախ հանդիպող տարբերակը:

*Միջինը* առավել հաճախ օգտագործվող վիճակագրական բնութագրիչներից է: Այն իրենից ներկայացնում է տվյալների «ծանրության կենտրոնը», որի շուրջ



կուտակված/սփռված են բոլոր դիտումները: Միջինը հաշվելու համար բոլոր տվյալների արժեքները գումարվում են, և արդյունքը բաժանվում այդ տվյալների քանակի վրա: Նմուշային միջինը նշանակվում է  $\bar{x}$ : Այսպիսով, ո ծավալ ունեցող  $(x_1, x_2, \dots, x_n)$  նմուշի միջինը հավասար է՝

$$\bar{x} = \frac{x_1 + x_2 + \dots + x_n}{n} = \frac{1}{n} \sum_{i=1}^n x_i$$

*Նմուշային մեդիանը* ( $x_{med}$ ) այն արժեքն է, որը բաժանում է փոփոխման շարքը երկու «հավասար» մասի ( $x_{med}$ -ից փոքր և  $x_{med}$ -ից մեծ) այնպես, որ խմբերում լինեն հավասար քանակությամբ արժեքներ:  $(x_1, x_2, \dots, x_n)$  նմուշի համար, որին համապատասխանում է  $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$  փոփոխման շարքը, մեդիանը որոշվում է հետևյալ բանաձևի օգնությամբ՝

$$x_{med} = \begin{cases} \frac{x_{(m)} + x_{(m+1)}}{2}, & \text{երբ } n = 2m \\ x_{(m)}, & \text{երբ } n = 2m - 1 \end{cases}$$

*Մոդ* (նշանակվում է՝  $x_{mod}$ ) կոչվում է նմուշային տվյալների ամենահաճախ հանդիպող արժեքը: Մոդը կարող է գոյություն չունենալ կամ միակը չլինել, այդ դեպքում բաշխումը կոչվում է բազմամոդալ:

*Ցրվածության բնութագրիչները* նկարագրում են տվյալների սփռվածությունը (spread): Դրանք են՝ նմուշի *լայնքը*, *ցրվածքը* (դիսպերսիան), ստանդարտ (միջին քառակուսային) *շեղումը*, *փոփոխման* (վարիացիայի) գործակիցը:

Պարզագույն ցրվածության բնութագրիչը *նմուշային լայնքն* է՝  $R = x_{(n)} - x_{(1)}$ , այսինքն՝ նմուշի մեծագույն և փոքրագույն արժեքների տարբերությունը:

Տվյալների բաշխվածությունը նկարագրող բնութագրիչներից են՝ *նմուշային ցրվածքը* (դիսպերսիան) և *ստանդարտ* կամ *միջին քառակուսային շեղումը*: Այդ

բնութագրիչները ցույց են տալիս միջին քառակուսային ցրվածությունը միջինի (սպասելի) շրջակայքում:

Դիցուք  $X$  հատկանիշին համապատասխանում է  $(x_1, x_2, \dots, x_n)$  նմուշը:

*Նմուշային ուղղված ցրվածք* (դիսպերսիա) կոչվում է հետևյալ մեծությունը.

$$s^2 = \frac{(x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \dots + (x_n - \bar{x})^2}{n - 1} = \frac{1}{n - 1} \sum_{i=1}^n (x_i - \bar{x})^2$$

որտեղ  $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$  նմուշային միջինն է:

*Նմուշային ստանդարտ կամ միջին քառակուսային շեղում* կոչվում է հետևյալ մեծությունը՝

$$s = \sqrt{s^2}$$

Ի տարբերություն դիտարկված ցրվածության բնութագրիչների՝ *փոփոխման (վարիացիայի) գործակիցը* իրենից ներկայացնում է ցրվածության հարաբերական չափը և արտահայտվում է տոկոսներով: Փոփոխման գործակիցը ցույց է տալիս տվյալների միջինի նկատմամբ ցրվածության չափը: Փոփոխման գործակից կոչվում է տոկոսներով արտահայտված նրա միջին քառակուսային շեղման հարաբերությունը նմուշային միջինի մոդուլին՝

$$v = \frac{s}{|\bar{x}|} * 100\%$$

Եթե  $v < 30\%$ , ապա տվյալները համարվում են համասեռ, դրանց հիմնական մասը գտնվում է միջինից ոչ շատ հեռու, և  $\bar{x}$  միջինը լավ է բնութագրում տվյալները: Եթե  $v > 30\%$ , ապա տվյալները համարվում են անհամասեռ, այսինքն՝ դրանց մեծ մասը գտնվում է  $\bar{x}$  միջինից հեռու, և նմուշային միջինը վատ է բնութագրում այդ տվյալները, այսինքն նումշը ներկայացուցչական չէ:

*Կառուցվածքային ցուցանիշներ:* Կառուցվածքային ցուցանիշների համակարգում, որպես բաշխման ձևի յուրահատկության ցուցանիշ, հանդես են գալիս տարբերակներ, որոնք որոշակի դիրք են գրավում (յուրաքանչյուր չորրորդը, հինգերորդը,

տասներորդը և այլն) վարիացիայի կարգավորված շարքում: Այդպիսի ցուցանիշները կրում են *քանորդիչ* ընդհանուր անվանումը:

Քանորդիչներից են, մասնավորապես, քառորդիչները, որոնք փոփոխման շարքը բաժանում են չորս հավասար մասերի: Տարբերվում են ստորին քառորդիչ ( $Q_1$ ), որն անջատում է համակցության  $\frac{1}{4}$  մասը՝ հատկանիշի ամենափոքր արժեքով, և վերին քանորդիչ ( $Q_3$ ), որը հատում է  $\frac{1}{4}$  մասը՝ հատկանիշի ամենամեծ արժեքով:

Դա նշանակում է, որ համակցության միավորների 25%-ի արժեքները փոքր են  $Q_1$ -ից, 25%-ը՝ գտնվում է  $Q_1$ -ի և  $Q_2$ -ի միջև, 25%-ը՝  $Q_2$ -ի և  $Q_3$ -ի միջև, և մնացած 25%-ը գերազանցում է  $Q_3$ -ը:

Երկրորդ քանորդիչը՝  $Q_2$ -ը մեղիանն է: Քանորդիչների հաշվարկը նման է մեղիանի հաշվարկմանը:

*Ռանգը* ոչ պարամետրական վիճակագրության հիմնական հասկացություններից է: Այն ներկայացնում է դիտարկումների դասավորությունը ըստ մեծության: Ռանգը տվյալ արժեքի կարգային համարն է այն շարքում, որտեղ բոլոր տվյալները դասավորված են աճման կարգով:

Օրինակ՝ ենթադրենք ունենք հետևյալ նմուշը՝ 3,2,4,3,5,4: Դասավորենք արժեքները աճման կարգով՝ 2,3,3,4,4,5: Նշենք յուրաքանչյուր արժեքը ռանգով՝ կարգով.

2-1, 3-2,3 (նույն արժեքի համար վերցնում ենք միջին ռանգը՝  $\frac{2+3}{2} = 2.5$ ), 4-4,5 (միջին ռանգը՝  $\frac{4+5}{2} = 4.5$ ), 5-6:

Վերջնական աղյուսակը՝

<i>Նմուշի արժեք</i>	2	3	3	4	4	5
<i>Ռանգ</i>	1	2.5	2.5	4.5	4.5	6

Ռանգը օգտագործվում է ոչ պարամետրական թեստերում՝ Վիլկոկսոնի, Կրուսկալ-Ուոլլիսի, Սպերմանի և այլն: Այս թեստերը հաշվի չեն առնում տվյալների բաշխումը, այլ համեմատում են ռանգերը, ոչ թե իրական թվային արժեքները:

*Վիճակագրական վարկածներ:* Շատ դեպքերում վիճակագրական մոդելավորումը իրականացվում է վիճակագրական վարկածների ստուգման միջոցով:  
*Վիճակագրական վարկածներ* հանուրի բաշխման օրենքի կամ որոշակի պարամետրերի հատկությունների վերաբերյալ ենթադրություններն են :

Հետազոտության նպատակն է լինում որոշել՝ ինչպես են համաձայնեցվում նմուշային տվյալները առաջադրված վարկածի հետ, կարելի է արդյոք նրանց միջև եղած անհամաձայնությունը վերագրել նմուշահանման ընթացքում առաջացած պատահական տատանումներին, թե վարկածը էապես հակասում է փորձնական տվյալներին և պետք է ժխտվի: Այդ խնդիրը լուծվում է մաթեմատիկական վիճակագրության հատուկ եղանակներով:

Առաջադրված վարկածի հիմնավորված համադրումը նմուշի հետ կատարվում է այս կամ այն *վիճակագրական հայտանիշի* օգնությամբ: Այդ գործողությունը անվանում են *վարկածի վիճակագրական ստուգում*: Վարկածի վիճակագրական ստուգման արդյունքը չի նշանակում, որ ենթադրվող պնդումը միակ հարմարն է:

Ստուգման ենթակա *վարկածը* նշանակում են  $H_0$  և անվանում հիմնական կամ զրոյական վարկած: Յուրաքանչյուր զրոյական վարկածին կարող է հակադրվել *երկրնտրանքային վարկածը*, որը նշանակում են  $H_1$ -ով:

Վարկածի վիճակագրական ստուգումը հիմնվում է փորձարկումների արդյունքների վրա և կարող է ընդունվել նաև սխալ որոշում: Վարկածների ստուգման սխալները լինում են ***երկու սեռի***: Եթե ստուգման արդյունքում ժխտվում է  $H_0$  վարկածը, երբ այն իրականում ճիշտ է, ապա ասում են, որ տեղի է ունեցել ***առաջին սեռի սխալ***՝  $P\{H_1|H_0\}=\alpha$  : Երբ  $H_0$  վարկածը ընդունվում է, երբ իրականում ճիշտ է երկրնտրանքային  $H_1$ -ը, ապա տեղի է ունեցել ***երկրորդ սեռի սխալ***՝  $P\{H_0|H_1\}=\beta$ :  $P\{H_1|H_1\}=1-\beta$   $H_1$ -ի վերաբերյալ ճիշտ որոշում կայացնելու հավանականությունն է: Վերջինս կոչվում է ***տեստի հզորությունն*** է: Դա այն հավանականությունն է, որ այլընտրանքային վարկածը իրականում ճիշտ լինելու դեպքում տեստը ճիշտ որոշում է կայացնում և մերժում է  $H_0$ -ն:

Վիճակագրական վարկածների ստուգման համար նախապես տրվում է առաջին սխալի հավանականությունը՝  $\alpha$ , որը կոչվում է նշանակալիության մակարդակ: Որոշումը կայացվում է հիմնվելով ստուգման հայտանիշի՝ տեստի ընդունած արժեքի վրա: Եթե այն թույլատրելի տիրույթից է, ապա ընդունվում է  $H_0$  վարկածը: Եթե կրիտիկական տիրույթից՝  $H_1$ : Բնականաբար վարկածի ստուգման համար առաջարկվող հայտնափոխներից լավ համարվում են նրանք, որոնց հզորությունը ավելի մեծ է:

## 2.2 Երեք և ավելի խմբերի համեմատման Կրուսկալ–Ուոլլիսի /Kruskal–Wallis/ հայտանիշ

Վիճակագրական հետազոտություններում հաճախ անհրաժեշտ է պարզել՝ արդյո՞ք որակական հատկանիշը ազդեցություն ունի որևէ քանակական արդյունքի վրա:

Որակական հատկանիշը կոչվում է գործոն, իսկ գործոնի ազդեցությանը ենթարկվող հատկանիշը՝ արդյունքային: Գործոնի յուրաքանչյուր արժեք կոչվում է մակարդակ: Ըստ էության գործոնը որակական հատկանիշն է, իսկ արդյունքայինը՝ քանակական: Քանի որ արդյունքային հատկանիշը միայն գործին ազդեցությանը չի ենթարկվում, այն նաև կարող է կախված լինել այլ պատահական մեծություններից, օրինակ, բուժման դեպքում. հիվանդի տարիք, իմունիտետ, գենետիկա և այլն, ապա հիմնավրվում է արդյունքային հատկանիշի պատահական բնույթ՝ պատահական մեծություն լինելը:

Վիճակագրական համապատասխան մեթոդների կիրառումը թույլ է տալիս գտնելու հետևյալ հարցերումա՞ր խնդրի լուծումը. կա՞ կապ որակական և քանակական հատկանիշների միջև: Եվ դրանց կիառմամբ լուծման ընթացքը ուղեկցվում է այն գործիքների ու մեթոդական մոտեցումների վրա, որոնք իսկ մաս են կազմում

տվյալների ուսումնասիրության, համեմատության, կապերի հայտնաբերման և որոշումներ կայացնելու գործընթացին:

Երեք և ավել մակարդակ ունեցող գործոնի ազդեցության բացահայտման խնդրի լուծումը իրականացվում է Կրուսկալ-Ուոլլիսի տեստի միջոցով:

$H_0$  զրոյական վարկածը ձևակերպվում է որպես խմբերի միջինների կամ կիսողների հավասարություն, որի դեպքում գործոնը ազդեցություն չունի, իսկ  $H_1$  այլընտրանքային վարկածի դեպքում առնվազն երկու խմբերի կիսողները իրար հավասար չեն՝ գործոնը ազդում է արդյունքային հատկանիշի վրա:

Թեստի իրականացումը կատարվում է ռանգերի միջոցով. դիտարկվող տվյալները որպես մեկ ամբողջություն դասավորվում են աճման կարգով և ստանում համապատասխան ռանգ՝  $R_{ij}$ , որտեղ  $j$ -ն խմբի համարն է,  $i$ -ն տվյալ խմբում դիտարկման կարգը:

Տեստը նկարագրելու համար դիտարկվում են հետևյալ մեծությունները՝

**Խմբային ռանգերի միջին ռանգը՝**

$$\bar{R}_j = \frac{1}{N_j} \sum_{i=1}^{N_j} R_{ij}$$

**Միավորված տվյալների ռանգերի միջին արժեքը՝**

$$\bar{R} = \frac{1}{N} \sum_{i=1}^L \sum_{j=1}^{N_j} R_{ij} = \frac{1}{N} \frac{N(N+1)}{2} = \frac{(N+1)}{2}$$

Ստուգման տեստը հետևյալն է՝

$$H = \frac{12}{N(N+1)} \sum_{j=1}^L N_j (\bar{R}_j - \bar{R})^2 = \frac{12}{N(N+1)} \sum_{j=1}^L \frac{R_j^2}{N_j} - 3(N+1)$$

Երբ  $H_0$  վարկածը ճիշտ է,  $H$ -ն մոտարկվում է  $L-1$  ազատության ասիճանով Խի-քառակուսի բաշխմամբ (այն պատահական մեծությունների անընդհատ բաշխում է, որն օգտագործվում է հատկապես կատեգորիական կամ ռանգավորված տվյալների

համար): Կրիտիկական տիրույթը աջակողմյան է, ուստի տրված նշանակալիության մակարդակին համապատասխան կրիտիկական կետից դիտարկման արժեքի մեծ լինելու դեպքում ընդունվում է որակական գործոնի ազդեցության վերաբերյալ վարկածը: